

<Logistic Regression & Softmax & Cross-Entropy Loss>

<Logistic Regression>

- **odds** : x 라는 데이터가 주어졌을 때, 성공(c_1)확률/실패(c_2)확률

$$: p(c_1|x) = y, p(c_2|x) = 1 - y$$

$$: y/(1 - y)$$

$$: \text{범위} : 0 < odds < \infty$$

- **logit** : odds에 log를 씌운 것

$$: \log(odds) = \log(y/(1 - y))$$

$$: \text{범위} : -\infty < \text{logit} < \infty$$

- $f(x)$ 의 결과값(z)를 logit으로 표현 $\rightarrow -\infty \leq \text{logit}(y)=z \leq \infty$

$$\log\left(\frac{y}{1-y}\right) = f(x)$$

$$\frac{y}{1-y} = e^{f(x)}$$

$$\frac{1-y}{y} = e^{-f(x)}$$

$$\frac{1}{y} = 1 + e^{-f(x)}$$

$$y = \frac{1}{1 + e^{-f(x)}}$$

- $f(x)$ 의 종속변수(z)를 sigmoid function의 입력값으로 $\rightarrow 0 \leq \text{sigmoid}(z)=y \leq 1$

$\rightarrow \text{logit}(y)=z, \text{sigmoid}(z)=y$ 이기 때문에, logit과 sigmoid는 역함수 관계

$\therefore f(x)$ 가 선형식일 때, sigmoid(t)로 regression하는 것 : Logistic Regression

<결정경계>

- logistic regression을 통한 class의 결정은 임계값(threshold)을 통해 이루어짐 $\rightarrow f(x)$ 의 값에 대한 임계값이 생김 \rightarrow 선형분류와 같음(즉 logistic regression은 비선형함수이지만, 비선형 분류를 할 수 있는 모델은 아님)

<Multiple Logistic Regression>

- 클래스가 k 개인 경우(C_1, C_2, \dots, C_k)

- C_k 를 기준으로 사용

$$- C_1 \text{에 대한 logit} = \log \frac{p(C_1|x)}{p(C_k|x)} = f_1(x)$$

$$- C_2 \text{에 대한 logit} = \log \frac{p(C_2|x)}{p(C_k|x)} = f_2(x)$$

$$- C_i \text{에 대한 logit} = \log \frac{p(C_i|x)}{p(C_k|x)} = f_i(x)$$

- C_k 에 대한 logit = $0 = \log \frac{p(C_k|x)}{p(C_k|x)} = f_i(x)$

-> exponential 형태로 표현한 후, class (1~k-1)까지의 양변을 더함

$$\sum_{i=1}^{k-1} \frac{p(C_i|x)}{p(C_k|x)} = \sum_{i=1}^{k-1} \exp(z_i)$$

$$p(C_k|x) = \frac{1}{1 + \sum_{i=1}^{k-1} \exp(z_i)}, \rightarrow p(C_i|x) = \frac{\exp(z_i)}{1 + \sum_{i=1}^{k-1} \exp(z_i)} \quad (C_i \text{에 대한 logit과 } p(C_k|x) \text{ 이용})$$

이 때, $1 = \exp(z_k)$ 이기 때문에 1 자리에 이를 대입

$$\rightarrow p(C_k|x) = \frac{\exp(z_k)}{\sum_{i=1}^k \exp(z_i)}, \quad p(C_i|x) = \frac{\exp(z_i)}{\sum_{i=1}^k \exp(z_i)} \rightarrow \text{"softmax}(z_i)\text{"}$$

<Cross Entropy Loss - Multiple Logistic Regression>

○ 각 클래스 예측 확률 : $\vec{y} = [p(C_1|x), p(C_2|x), \dots, p(C_k|x)]$

○ 각 클래스 실제 확률 : $\vec{t} = [t_1, t_2, \dots, t_k]$ (만약 클래스 1이라면 $[1, 0, \dots, 0]$)

-> Cross Entropy($H(p|q) = -\sum_{i=1}^n p_i \log(q_i)$)를 이용하여 예측의 Loss를 구함

$$L = -\sum_{i=1}^k t_i \log y \rightarrow \text{"cross entropy loss"}$$

<Cross Entropy Loss - Binary Logistic Regression>

○ 예측 값 : $y = P(C_1|x)$

○ 실제 값 : $t = 1 \text{ or } 0$

-> Cross Entropy를 이용하기 위해 예측값과 실제값 변환

- 예측값 : $\vec{y} = [y, 1-y]$

- 실제값 : $\vec{t} = [0, 1]$

$$L = -\sum_{i=1}^2 t_i \log y = -[t \log(y) + (1-t) \log(1-y)] \rightarrow \text{"cross entropy loss"}$$

<Log Loss & Cross Entropy Error>

- binary classification일 때, log likelihood를 최대화 하는 것은 CEE를 최소화하는 것과 같음
따라서 CEE는 log loss 혹은 negative log likelihood로 불리기도 함
ex)

- D: binary classification 문제의 어떤 dataset(데이터 개수:n개)

- y : target이 1일 확률

-> $likelihood = p(D|y)$

$$= \prod_{i=1}^n (\theta)^{t_i} (1-\theta)^{1-t_i}$$

$$\therefore \log - \text{likelihood} = \sum_{i=1}^n (t_i \log y_i + (1-t_i) \log (1-y_i)) = - \text{CEE}$$

해당 식은 binary-classification의 cross-entropy의 음과 같음

$$- (\text{하나의 } x \text{에 대한 } \log\text{-likelihood} = [t \log(y) + (1-t) \log(1-y)] = - \text{CEE})$$