

<Logistic Regression & Softmax & Cross-Entropy Loss>

<Logistic Regression>

- **odds** : x 라는 데이터가 주어졌을 때, 성공(c_1)확률/실패(c_2)확률
 - : $p(c_1|x) = y, p(c_2|x) = 1 - y$
 - : $y/(1 - y)$
 - : 범위 : $0 < odds < \infty$
- **logit** : odds에 log를 씌운 것
 - : $\log(odds) = \log(y/1 - y)$
 - : 범위 : $-\infty < \text{logit} < \infty$

- $f(x)$ 의 결과값(z)를 logit으로 표현 $\rightarrow -\infty \leq \text{logit}(y)=z \leq \infty$

$$\log\left(\frac{y}{1-y}\right) = f(x)$$

$$\frac{y}{1-y} = e^{f(x)}$$

$$\frac{1-y}{y} = e^{-f(x)}$$

$$1/y = 1 + e^{-f(x)}$$

$$y = \frac{1}{1 + e^{-f(x)}}$$

- $f(x)$ 의 종속변수(z)를 sigmoid function의 입력값으로 $\rightarrow 0 \leq \text{sigmoid}(z)=y \leq 1$
- $\rightarrow \text{logit}(y)=z, \text{sigmoid}(z)=y$ 이기 때문에, logit과 sigmoid는 역함수 관계
- $\therefore f(x)$ 가 선형식일 때, sigmoid(t)로 regression하는 것 : Logistic Regression

<결정경계>

- logistic regression을 통한 class의 결정은 임계값(threshold)을 통해 이루어짐 $\rightarrow f(x)$ 의 값에 대한 임계값이 생김 \rightarrow 선형분류와 같음(즉 logistic regression은 비선형함수이지만, 비선형 분류를 할 수 있는 모델은 아님)

<Multiple Logistic Regression>

- 클래스가 k 개인 경우(C_1, C_2, \dots, C_k)
- C_k 를 기준으로 사용
- C_1 에 대한 logit = $\log \frac{p(C_1|x)}{p(C_k|x)} = f_1(x)$
- C_2 에 대한 logit = $\log \frac{p(C_2|x)}{p(C_k|x)} = f_2(x)$
- C_i 에 대한 logit = $\log \frac{p(C_i|x)}{p(C_k|x)} = f_i(x)$

- C_k 에 대한 logit = $0 = \log \frac{p(C_k|x)}{p(C_k|x)} = f_i(x)$

-> exponential 형태로 표현한 후, class (1~k-1)까지의 양변을 더함

$$\sum_{i=1}^{k-1} \frac{p(C_i|x)}{p(C_k|x)} = \sum_{i=1}^{k-1} \exp(z_i)$$

$$p(C_k|x) = \frac{1}{1 + \sum_{i=1}^{k-1} \exp(z_i)}, \rightarrow p(C_i|x) = \frac{\exp(z_i)}{1 + \sum_{i=1}^{k-1} \exp(z_i)} \quad (C_i \text{에 대한 logit과 } p(C_k|x) \text{ 이용})$$

이 때, $1 = \exp(z_k)$ 이기 때문에 1 자리에 이를 대입

$$\rightarrow p(C_k|x) = \frac{\exp(z_k)}{\sum_{i=1}^k \exp(z_i)}, \quad p(C_i|x) = \frac{\exp(z_i)}{\sum_{i=1}^k \exp(z_i)} \rightarrow \text{"softmax}(z_i)\text{"}$$

<Logistic Regression with MLE>

o Logistic Regression의 각 클래스 확률 출력 : $\vec{y} = [p(C_1|x), p(C_2|x), \dots, p(C_k|x)]$

o 실제 해당 데이터의 각 클래스 확률 : $\vec{t} = [t_1, t_2, \dots, t_k]$ (만약 클래스1이라면 $[1, 0, \dots, 0]$)

o (하나의 x에 대해) Logistic Regression의 목적 : $\argmax \text{likelihood}(p(D|W))$

$$= p(\vec{t}|\vec{x}, W)$$

$$= p(\vec{t}|\vec{y})$$

$$= \prod_{i=1}^k y_i^{t_i} (1 - y_i)^{1-t_i}$$

(정답 class는 해당 class일 확률이 곱해지고, 정답이 아닌 class에서는 해당 class가 아닐 확률이 곱해져야 하기 때문)

-> 목적식에 log를 씌움

$$\argmax \sum_{i=1}^k t_i \log y_i + (1 - t_i) \log (1 - y_i)$$

-> -1을 곱함으로써 최소화문제로 변환

$$\argmin \sum_{i=1}^k t_i \log y_i^{-1} + (1 - t_i) \log (1 - y_i)^{-1} \rightarrow \text{"cross entropy loss"}$$

<Cross-entropy-Loss>

- binary classification일 때, logistic regression의 목적식이 cross-entropy와 같기 때문에 이를 **cross-entropy-loss**라고 부르기도 함. cross-entropy 역시 negative log likelihood로 불리기도 함.